Приёмы и стратегии работы с MapReduce

Kirill Danilyuk, Yandex SDC

How MapReduce Works?

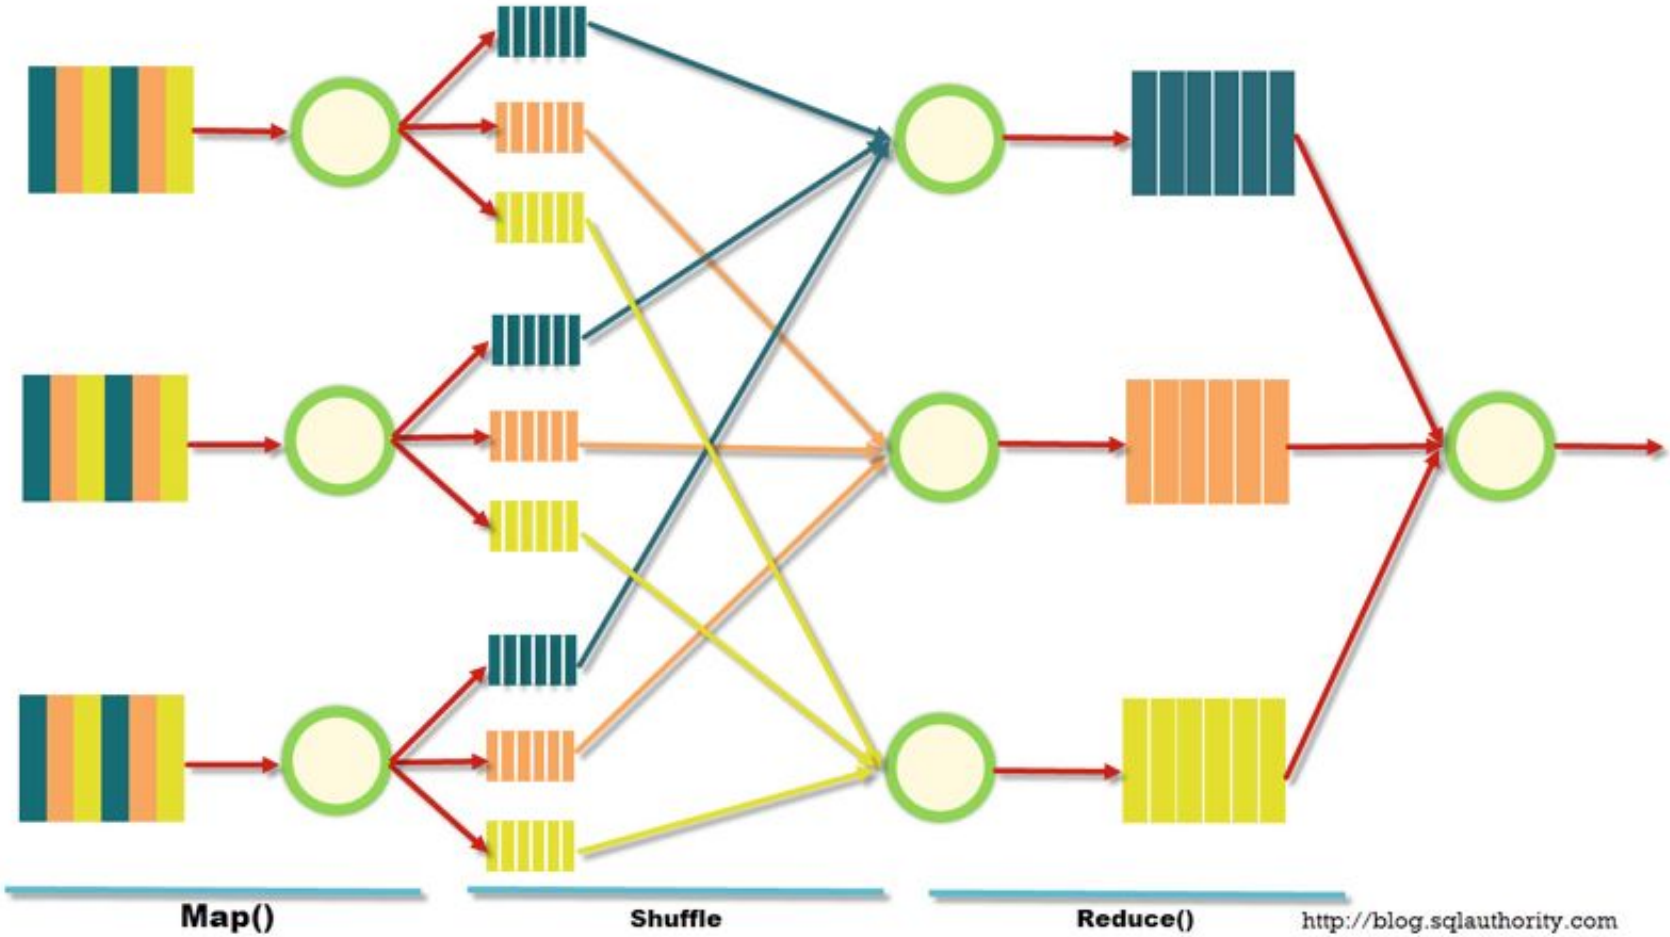

Уровни абстракции MapReduce

Уровень 0: примитивы `map` и `reduce`

Уровень 1: концептуальная модель в рамках пейпы от Google 2004 года

Уровень 2: (сегодняшнее занятие) утилизация парадигмы MapReduce в виде кода, реализующего Mapper и Reducer

Уровень 3: реализация MapReduce в виде фреймворка, абстрагирующего инженерные аспекты работы

```
map(String key, String value):
  // key: document name
  // value: document contents
  for each word w in value:
    EmitIntermediate(w, "1");

reduce(String key, Iterator values):
  // key: a word
  // values: a list of counts
  int result = 0;
  for each v in values:
    result += ParseInt(v);
  Emit(AsString(result));
```

Map, `Mapper`, `map`

Map: шаг в терминах фреймворка

`Mapper`: интерфейс в терминах Java API. Отображает исходные key/value пары в набор intermediate key/value пар

`map`: процедура, которую необходимо реализовать в рамках интерфейса. Трансформирует одну пару key с value.

```
public class TokenCounterMapper
     extends Mapper<Object, Text, Text, IntWritable>{

   private final static IntWritable one = new IntWritable(1);
   private Text word = new Text();

   public void map(Object key, Text value, Context context)
       throws IOException, InterruptedException {
     StringTokenizer itr = new StringTokenizer(value.toString());
     while (itr.hasMoreTokens()) {
       word.set(itr.nextToken());
       context.write(word, one);
     }
   }
 }
```

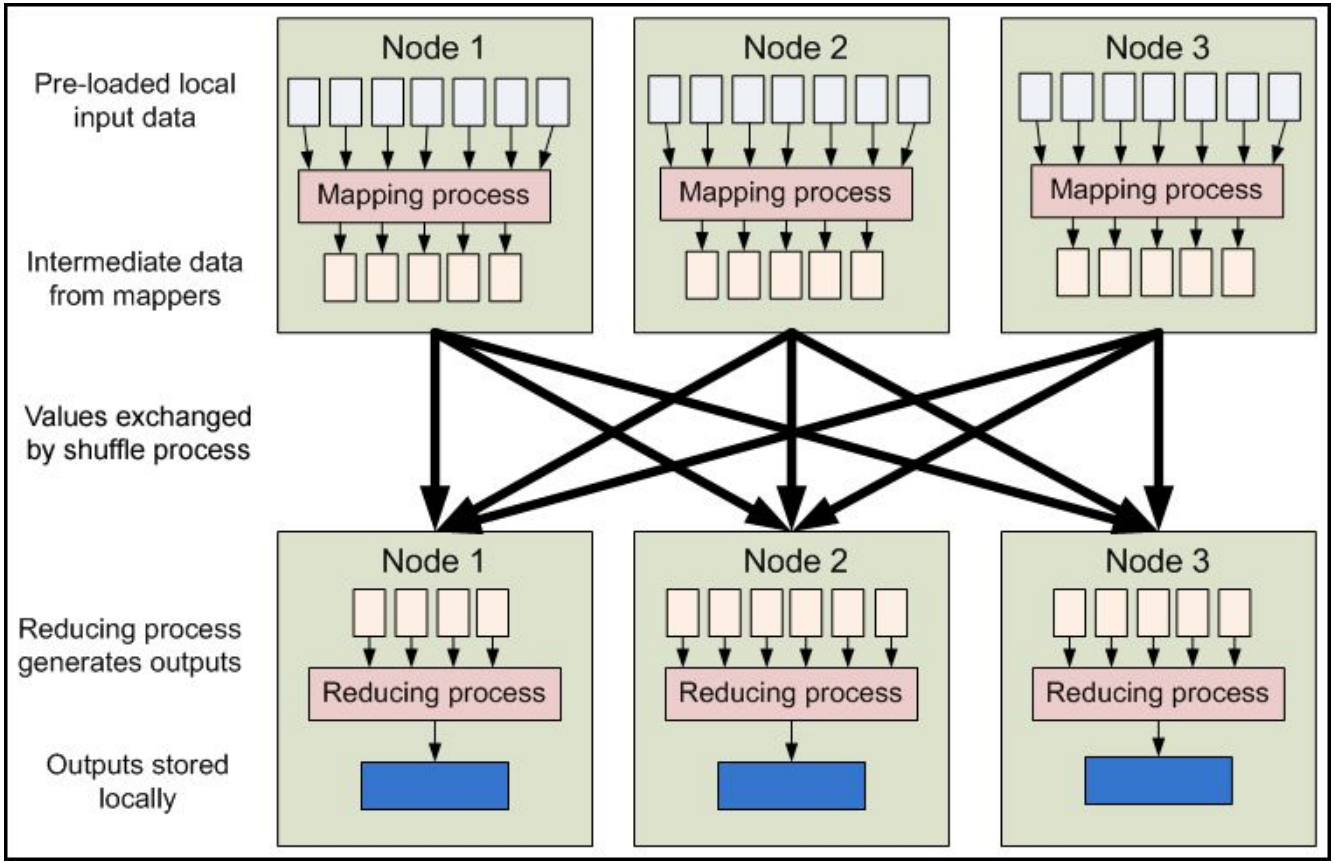

https://developer.yahoo.com/hadoop/tutorial/module4.html

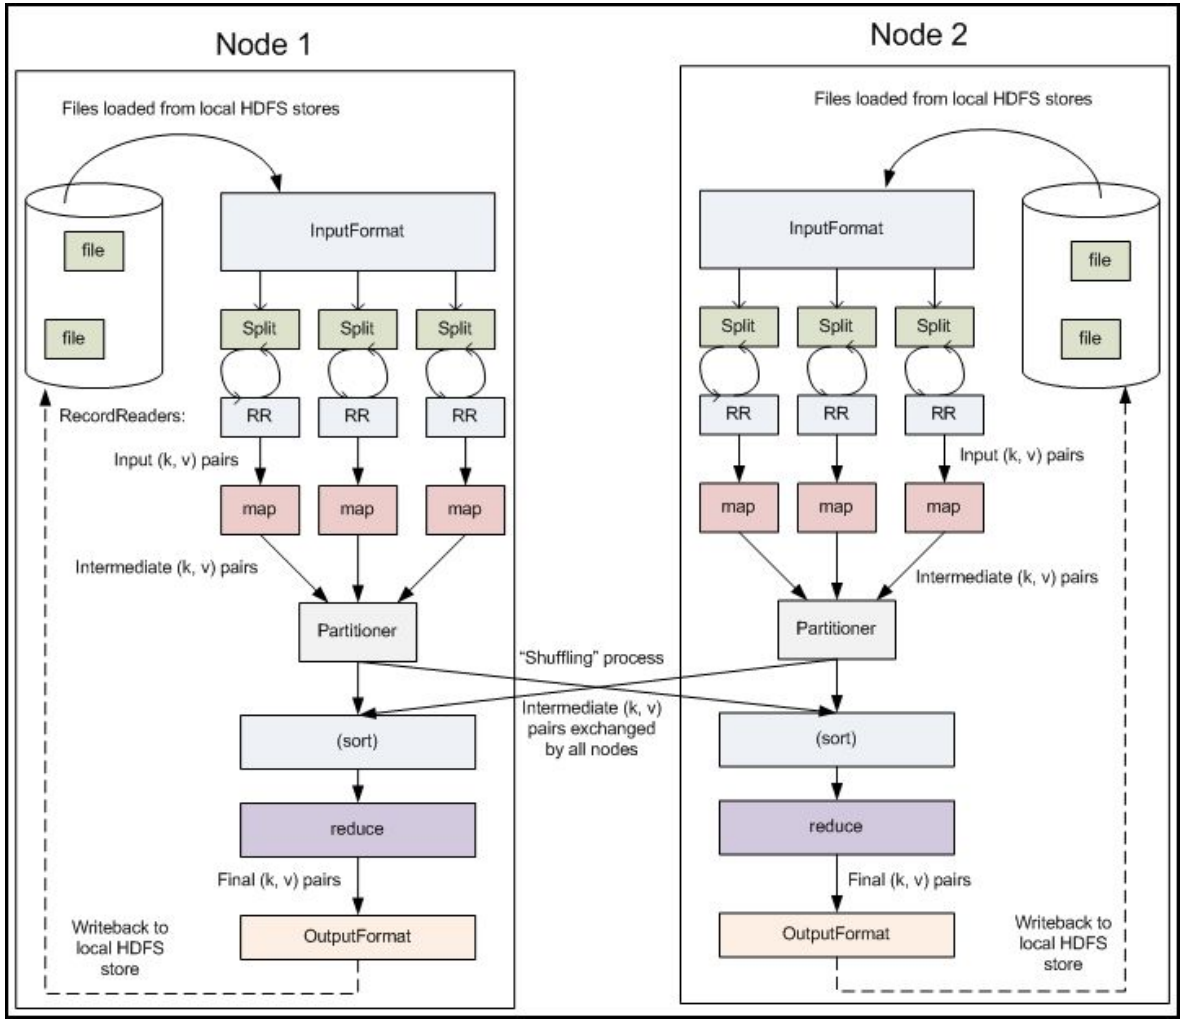

https://developer.yahoo.com/hadoop/tutorial/module4.html

0. Word Count (пример)

Работа на кластере

Работать будем на master-машине, зайдите на неё сейчас по ssh.

Скопируйте себе в домашнюю директорию master-машины данные из hadoop-кластера по адресу: `/tmp/mapreduce_seminar/data`

После занятия ответы будут доступны в директории `/tmp/mapreduce_seminar/solutions` кластера.

Локальная отладка

```
$ cat data/doc.txt | python3 mapper.py | sort
-k1,1 | python3 reducer.py > data/result.txt
```

Вспомним Word Count

```python
# mapper.py

import sys

for line in sys.stdin:
    for token in line.strip().split():
        print(token + '\t1')
```

```python
# reducer.py

import sys

prev_key = None
sum = 0

for line in sys.stdin:
    key, value = line.split("\t")
    if key != prev_key and prev_key is not None:
        print(prev_key, sum)
        sum = 0
    sum += 1
    prev_key = key

if key != prev_key and prev_key is not None:
    print(prev_key, sum)
```

```python
import sys

# Accumulators
prev_key = None
values = []

# reduce() method
def do_reduce(key, values):
    yield key, sum(values)

# Reducer
for line in sys.stdin:
    key, value = line.split("\t")
    if key != prev_key and prev_key is not None:
        for k, v in do_reduce(prev_key, values):
            sys.stdout.write('{},{}\n'.format(k, str(v)))
        values = []
    values.append(int(value))
    prev_key = key

# Off by one correction
if key != prev_key and prev_key is not None:
    for k, v in do_reduce(prev_key, values):
        sys.stdout.write('{},{}\n'.format(k, str(v)))
```

Word Count (Reducer)

Оформление задачи

```
# mapper:
map(x) →
for token in x.split():
    emit(token, 1)
```

```
# reducer:
reduce(key, values) →
    emit(key, sum(values))
```

1. Поиск отличников

Поиск отличников

Дан файл вида студент<tab>оценка

- Фейн 3
- Куликов 4
- Петровна 3
- Мордовина 4
- Коробейников 5
- Кремнев 5
- Мордовина 3

Студент считается отличником, если его средний балл >= **4.5**. Найти всех отличников в файле.

Поиск отличников

```
# mapper
map(x, score) →
    emit (x, score)
```

```
# reducer
reduce(x, scores) →
    avg = average(scores)
    if avg >= 4.5:
        emit(x, avg)
```

Поиск отличников (решение)

```python
# mapper

import sys
for line in sys.stdin:
    print(line.strip())
```

```python
# reducer
import sys

prev_student = None
marks = []

def emit_top_student_result(student, mk):
    avg = sum(mk) / len(mk)
    if avg >= 4.5: print('{}: {:.2f}'.format(student, avg))

for line in sys.stdin:
    key, value = line.strip().split("\t")
    if key != prev_student and prev_student is not None:
        emit_top_student_result(prev_student, marks)
        marks = []
    marks.append(float(value))
    prev_student = key

if prev_student is not None:
    emit_top_student_result(prev_student, marks)
```

2. Гистограмма оценок

Гистограмма

Ожидаемый результат:

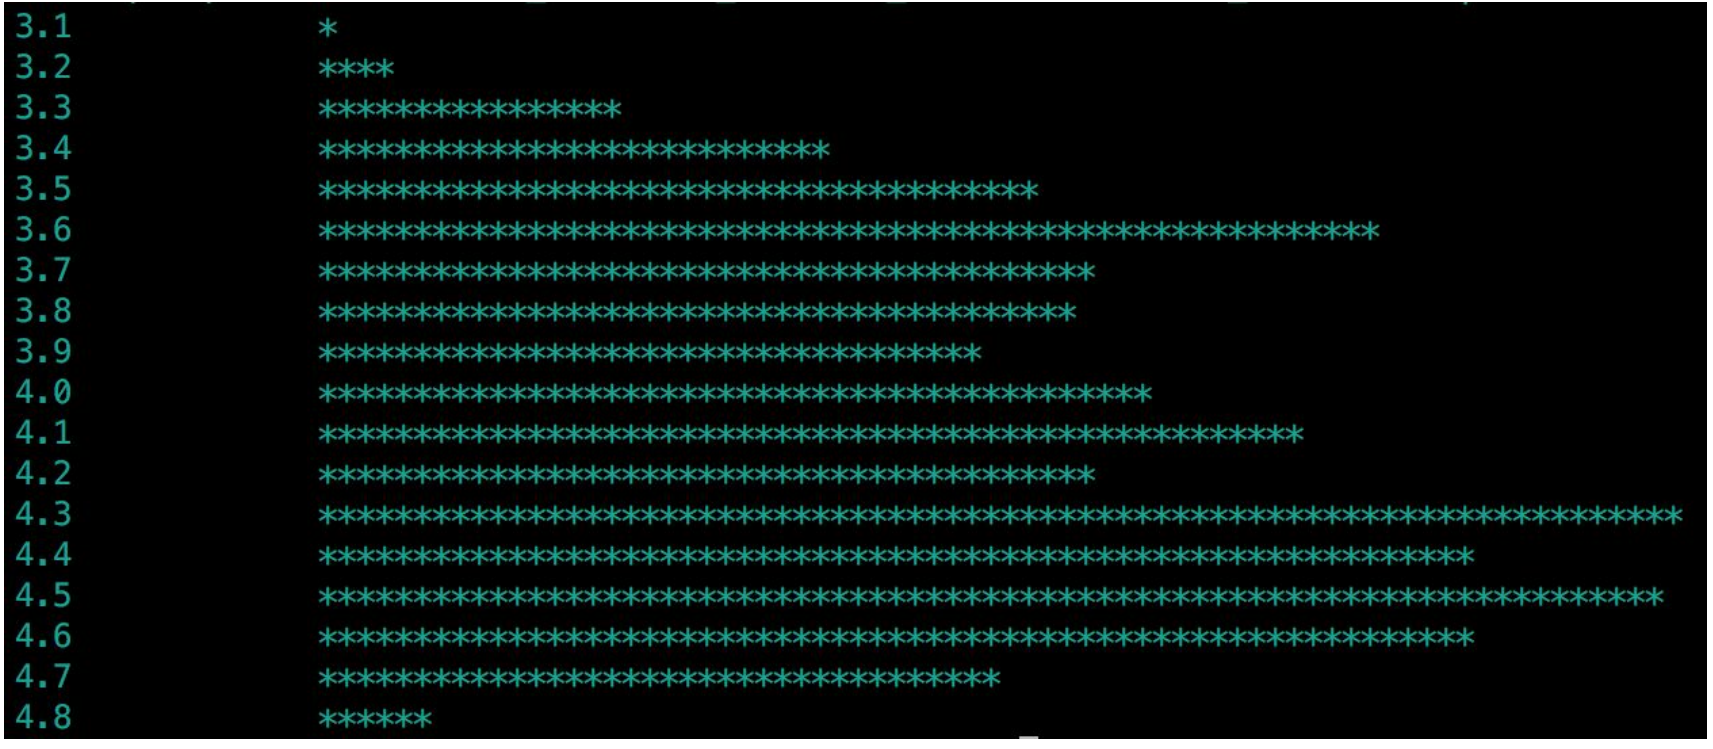

Гистограмма (решение)

JOB 1:

- mapper – Identity
- reducer(key, value) →
  emit(avg(values), 1)

JOB 2:

- mapper – Identity
- reducer(key, values) ->
  emit (key, “*”*sum(values)

Гистограмма (код)

```python
# Reduce 1

import sys

prev_student = None
marks = []

def emit_student_result(student, mk):
    res = sum(mk) / len(mk)
    print('{:.1f}\t{}'.format(res, 1))

for line in sys.stdin:
    key, value = line.strip().split("\t")
    if key != prev_student and prev_student is not None:
        emit_student_result(prev_student, marks)
        marks = []
    marks.append(float(value))
    prev_student = key

if prev_student is not None:
    emit_student_result(prev_student, marks)
```

```python
# Reduce 2
import sys

prev_mark = None
marks = []

def emit_histogram_value(mark, ones):
    res = '*' * sum(ones)
    print('{:10}\t{}'.format(mark, res))

for line in sys.stdin:
    key, value = line.strip().split("\t")
    if key != prev_mark and prev_mark is not
None:
        emit_histogram_value(prev_mark, marks)
        marks = []
    prev_mark = key
    marks.append(1)

if prev_mark is not None:
    emit_histogram_value(prev_mark, marks)
```

3. Map-Only Jobs

Map-Only Jobs

- Исходный файл - как в примере №1
- Оставить записи только по студентам с фамилией начинающейся на «П»

Map-Only Jobs (решение)

```
# mapper:
mapper(key, value) ->
    if key.startswith(’П’):
        emit (key, value)
```

4. Reduce Joins

Средняя оценка vs любимый предмет

- **Файл 1** — как в первом задании
- **Файл 2** — <user>\t<любимый предмет>

Посчитать среднюю оценку среди любителей данного предмета

Как вообще решить эту задачу?

Pandas:

```
marks = pd.read_csv('student_scores.txt', header=None,
                    names=['user_id', 'mark'], sep='\t')

fav = pd.read_csv('student_disciplines.txt', header=None,
                  names=['user_id', 'discipline'], sep='\t')

pd.merge(fav, marks.groupby('user_id').mean().reset_index(),
         how='left', on='user_id').groupby('discipline').mean()
```

Reduce Joins

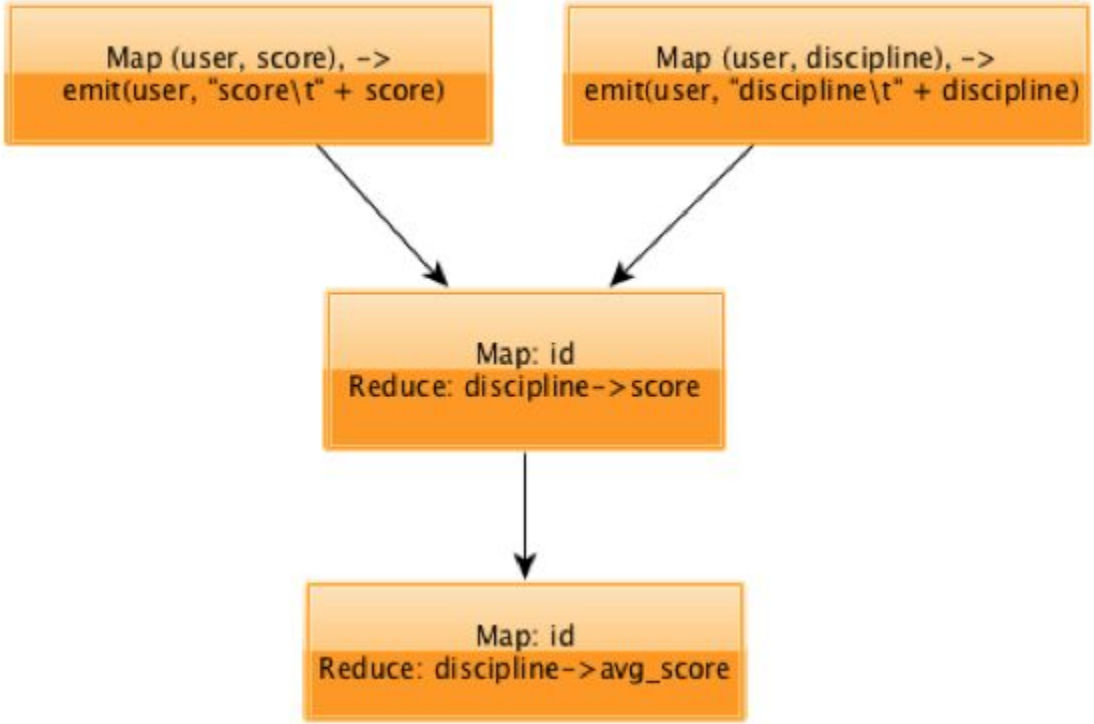

Код мапперов

```
# Mapper 1
import sys
for line in sys.stdin:
    user, score =
line.strip().split()
    print (user + "\t" +
"score" + "\t" + score)
```

```
# Mapper 2
import sys
for line in sys.stdin:
    user, discipline =
line.strip().split()
    print (user + "\t" +
"discipline" + "\t" +
discipline)
```

Reducer (1)

```
import sys
prev_key = None
values = []

def print_res(key,  values):
    scores = [float(score[1]) for score in filter(lambda value: value[0] == 'score', values)]
    avg = sum(scores)/len(scores)
    discipline = list(filter(lambda value: value[0] == 'discipline', values))[0][1]
    print("%s\t%.2f" % (discipline, avg))

for line in sys.stdin:
    key, record_type, value = line.strip().split("\t")
    if key != prev_key and prev_key is not None:
        print_res(prev_key, values)
        values = []
    values.append((record_type, value))
    prev_key = key

if prev_key is not None:
    print_res(prev_key, values)
```

Reducer (2)

```
import sys
prev_key = None
marks = []

def print_res(key, values):
    avg = sum(values)/len(values)
    print("%s\t%.2f" % (key, avg))

values = []
for line in sys.stdin:
    key, value = line.strip().split("\t")
    if key != prev_key and prev_key is not None:
        print_res(prev_key, values)
        values = []
    values.append(float(value))
    prev_key = key

if prev_key is not None:
    print_res(prev_key, values)
```

Reduce Join: локальная отладка

```
cat data/student_scores.txt | python mapper_3_1.py > data/tmp
cat  data/student_disciplines.txt | python mapper_3_2.py  >>
data/tmp
sort -k1,1 data/tmp |python reducer3_1.py > data/reducer3_1_output
sort -k1,1 data/reducer3_1_output | python reducer3_2.py
```

Distributed Cache

Механизм в hadoop позволяющий добавить ресурсы в окружение map-reduce задачи

Синтаксис:

```
yarn jar … streaming.jar … -file ‘data.txt’
```

Можно использовать `data.txt` как локальный файл

Кроме локальных файлов можно добавлять данные с HDFS

5. Map Joins

Map Join

Подсчет средней оценки по предмету без усреднения по пользователям

Map Join

```python
import sys
student_disciplines = {}
for line in open('student_disciplines.txt'):
    student, discipline = line.strip().split("\t")
    student_disciplines[student] = discipline

for line in sys.stdin:
    student, score = line.strip().split('\t')
    print(student_disciplines[student] + "\t" + score)
```

```python
import sys
prev_key = None
values = []

def print_res(key,  values):
    avg = sum(values)/len(values)
    print("%s\t%.2f" % (key, avg))

for line in sys.stdin:
    key, value = line.strip().split("\t")
    if key != prev_key and prev_key is not None:
        print_res(prev_key, values)
        values = []
    values.append(float(value))
    prev_key = key

if prev_key is not None:
    print_res(prev_key, values)
```

Спасибо!